

Know When to Fuse, Non-English Hybrid Retrieval in the Legal Domain



Boost RAG와의 심도 비교

“Know When to Fuse” 논문 요약 및 핵심 기술 분석

비영어권 법률 도메인에서의 하이브리드 검색: *Know When to Fuse: Investigating Non-English Hybrid Retrieval in the Legal Domain* 논문은

프랑스어 법률 문서 환경에서 하이브리드 검색 기법의 효과를 정밀 분석한 연구

하이브리드 검색

전통적인 어휘 기반 검색(lexical retrieval)과

의미 기반 검색(semantic/dense retrieval)의 장점을 결합

개별 기법의 한계를 보완하는 검색 전략을 뜻

어휘 기반 방법(예: BM25)은 질의어와 문서 간 **정확한 용어 일치**를 활용하여 효율적이고 폭넓은 검색을 제공하지만, 질의어가 문서에 그대로 나타나지 않는 경우(어휘 격차 문제) 관련 정보를 놓칠 수 있음.

의미 기반 방법(예: 미리 학습된 임베딩을 사용하는 Dense Retriever)은 질의어와 문서 간 **의미 유사도**를 학습하여 어휘가 직접 일치하지 않아도 관련 문서를 찾을 수 있지만, 새로운 도메인이나 특수 분야에 대한 일반화 성능이 떨어질 수 있음.

법률과 같은 전문 도메인에서는 대량의 도메인별 학습데이터가 부족하고, 일반 언어와 법률 용어 간 차이가 큼 -> 일반화 문제와 어휘 격차 문제 두드러짐

논문의 목적과 실험 구성:

본 논문은 프랑스 법률 질의응답 데이터셋을 활용하여, 다양한 검색 모델 조합이 영어가 아닌 법률 도메인에서 어떻게 성능을 보이는지 평가

실험에는

대표적인 희소(**lexical**) 모형인 BM25와,

밀집(**dense**) 모형들

(DPR (Dense Passage Retriever),

ColBERT (contextual late interaction retriever),

SPLADE (스파스 모델의 일종),

다국어 E5 임베딩 모델 등)이 포함

모델을 별도 법률 데이터로

미세조정하지 않은 경우(zero-shot, 도메인 일반 모델들의 조합)와

법률 **QA** 코퍼스에 미세조정된 경우(in-domain, 도메인 특화 모델들의 조합)

두 시나리오에서 하이브리드 검색의 효과를 비교

또한 **Late Fusion** 기법들을 활용하여 결과를 결합했는데,

이는 각 검색기의 결과를 사후에 결합하는 방식으로,

검색 단계에서 서로 다른 모델의 **랭킹 리스트** 또는 **점수**를 융합.

점수 기반 융합(score fusion)과 순위 기반 융합(rank fusion)을 모두 실험,

점수 기반 융합(score fusion)

정규화된 점수 합산(Normalized Score Fusion, NSF) 방법

순위 기반 융합(rank fusion)

보르다 카운트(Borda Count) 및 상호 순위 융합(Reciprocal Rank

Fusion, RRF)




Figure 1: A high-level illustration of the hybrid search workflow based on various sparse and dense retrievers.

_그림 1: 하이브리드 검색의 개략적 구조

하나의 법률 질의에 대하여 BM25 같은 희소 모델과 DPR, ColBERT 같은 밀집 모델들이 병렬적으로 관련 법률 조각(조문, 판례 등)을 검색하고, **Fusion** 모듈이 각 검색 결과(점수 또는 순위)를 **융합**하여 최종 순위를 산출

하이브리드 검색 최적화와 성능:

도메인 특화 학습이 없는 상태(**Zero-shot**)

에서는 서로 다른 유형의 검색기를 조합함으로써

일관되게 성능 향상을 달성할 수 있음 .

예를 들어,

BM25 (어휘 매칭)와 DPR 및 CoBERT (의미 매칭) 세 가지를 융합하면 단일 모델을 사용할 때보다

검색 성능(예: **Recall@10**)이 4%p 이상 향상되었고,

DPR이나 CoBERT 단독 대비 약 26% 상대적 성능 우위,

. 특히 BM25와 SPLADE 같이 두 희소 모델을 결합한 경우는 대용량 재현율 (**Recall@500**) 지표에서 가장 뛰어난 성능을 냄,

두 모델 모두 역색인(inverted index)을 활용하므로

결합 후에도 상대적으로 효율성(메모리 및 속도)이 유지되는 장점이 있었습니다 . 이러한 결과는 서로 다른 매칭 패러다임의 결합이 각 기법의 약점을 보완하여,

법률처럼 전문용어와 일상어 간 차이가 큰 도메인에서도

초기 학습 데이터 없이 높은 검색 품질을 얻도록 해준다는 점을 입증

실제 논문에서도 “도메인 일반 모델들의 결합은 개별 모델 단독 사용에 비해 항상 성능을 향상시켰다”고 보고하고 있습니다 .

이는 기존 연구들이 영어 일반 도메인에서 BM25+Dense 정도의 제한된 조합만 다룬 데 반해, 새로운 언어와 분야에서도 하이브리드 검색의 이점이 확인된 중요한 결과입니다 .

도메인 내에서 학습이 이루어진 경우(in-domain)

****in-domain에서는 양상이 달라짐.**

소량의 프랑스 법률 QA 데이터로 DPR, CoBERT 등의 모델을 미세조정하자 각 개별 모델의 법률 질의응답 적합도가 향상되었고, 이때는 하이브리드 융합이 오히려 성능을 떨어뜨리는 경우가 많았다고 합니다. 논문의 상세 분석에 따르면, 조합 가능한 모델 쌍/조합 중 약 **70%**가 단일 최우수 모델보다 성능이 저하되었고, 나머지 30% 가량만 미세한 향상을 보였습니다 . 더욱이 in-domain 상황에서 하이브리드로 얻는 이득 폭도 매우 제한적이어서, 두 모델

결합시 최대 향상이 **1.4%** 이내에 그친 반면, 도메인 일반(미학습) 상황에서는 최대 **7.1%p** 향상까지 관찰되었던 것과 대조적입니다 .

이는 도메인에 맞춰 충분히 성능이 향상된 단일 모델이 존재한다면, 추가 모델과의 결합으로 얻는 이득이 크지 않거나 오히려 노이즈 융합 효과로 성능이 악화될 수 있음.

BM25 + (미세조정된) DPR 조합을 살펴보면,
DPR을 법률 코퍼스에 학습시킨 이후에는
BM25 결과를 결합해도 거의 도움이 되지 않았고,
동일 가중치로 단순 결합할 경우
일관되게 **DPR** 단독보다 성능이 낮았다고 보고 .

왜그런가?

이는 학습되지 않은 상태에서는 BM25가 DPR의 약점을 보완해주지만, 학습 후에는 DPR 자체가 법률 용어 패턴을 어느 정도 익혔기 때문에 BM25의 기여도가 상대적으로 감소하거나, 잘 학습된 모델의 판단을 방해하는 영향을 줄 수 있음을 보임

. 따라서 “언제 융합할 것인가”에 대한 답은: 라벨된 데이터가 부족한 경우나 새로운 도메인에 처음 적용하는 경우에는 하이브리드 검색으로 이득을 볼 가능성이 높지만,

충분한 도메인 학습이 이루어진 상황**에서는 신중하게 융합을 조정하지 않으면 오히려 단일 모델만 못할 수 있다는 것

이처럼 하이브리드 검색을
최적화하려면 상황에 따른 전략이 필요
특히 도메인 특화 상황에서는
각 검색기의 기여도를 세밀하게 조정하는 것이 핵심

Adaptive Fusion 기법 및 개선

위 결과와 직결되는 중요한 기술 요소 -> Fusion 기법.

논문에서는 Late Fusion 방식을 택해
개별 검색기의 결과 점수 또는 순위를 사후적으로 결합했으며,
여러 Fusion 알고리즘을 비교 .

대표적으로
정규화된 점수 합산 (NSF),
Borda count 방식,
Reciprocal Rank Fusion (RRF)을 실험

각 방법은 서로 다른 검색기의 결과 점수 분포와
순위 정보를 결합하여 최종 순위를 매기는 기법

Score Fusion:

각 검색 모델이 산출한 relevance score를 일정한 범위로 정규화한 후합산
하거나 가중합하는 방법

Score Fusion의 장점

“이 문서가 전반적으로 얼마나 관련 있는가”를 수치로 결합하는 것

Score Fusion의 문제

다른 모델들 간 점수 분포의 스케일 차이
->부정확한 결합이 될 수 있다는 문제.
실제로 논문에서도 각 모델의 점수 분포를 비교했는데,
전통적인 min-max 정규화의 경우
모델 간 점수 분포 정렬이 맞지 않는(misaligned) 현상

예를 들어 동일하게 0.35로 정규화된 점수라도
DPR에서는 약 중간 정도의 점수값이지만
BM25에서는 상위 5% 이내의 매우 높은 점수에 해당했다고 합니다 . 이러한
차이를 모르고 단순 합산하면,

BM25가 강한 신호로 준 고득점 문서가 DPR 쪽에서는 평범한 점수로 간주되어 상쇄되어 버릴 수 있습니다 .

이를 위해 백분위 정규화(percentile scaling)라는 기법을 제안

백분위 정규화(percentile scaling)

각 모델의 점수 분포(코퍼스 전체에 대한 점수 분포)를 미리 계산한 뒤, 특정 문서의 점수를 해당 모델에서의 백분위 값으로 변환하는 것

이렇게 하면 앞의 예에서

BM25의 0.35점은 95백분위로,

DPR의 0.35점은 50백분위로 조정되어,

BM25에서 높은 관련성을 나타내는 문서에 더 높은 가중치

직관적으로는 합리적인 방법이지만, 저자들의 실험 결과,

백분위 기반 정규화가 기존 단순 정규화들보다 일관되게 우수 X

이는 아마도 백분위로 변환하면서 세밀한 점수 차이가 묻히거나, 코퍼스 규모와 분포 추정의 어려움 때문으로 추정.

그럼에도 불구하고 이러한 시도는

이종 모델 간 점수 결합의 어려움을 인지하고 개선하려는 노력,

향후 연구에서 보다 적응적인 점수 스케일링 방법 개발의 필요성 부각

순위 기반 융합 (Rank Fusion):

각 검색 모델이 산출한 순위 자체를 결합하는 방법

대표적으로 **Borda count**와 **RRF**를 사용.

Borda count는 여러 순위 리스트에서 얻은 순위 점수 누적하여 정렬

RRF는 각 모델에서의 순위 r 에 대해 $1/(k + r)$ (k 는 작은 상수) 형태로

가중치를 부여한 후 합산하는 방식.

순위 기반 융합은 모델 간 점수 분포 차이를 신경쓰지 않아도 된다는 장점, 실험에서도 특별한 튜닝 없이도 견고한 성능을 보이는 것.

특히 RRF는 과거 연구에서도 하이브리드 검색에서 효과적인 것으로 알려져 있고 , 이번 실험의 zero-shot 환경에서도 가중치 튜닝 없이 좋은 성능을 보인 소수의 방법 중 하나.

순위 기반 융합의 한계

다만 순위 기반 방법은 새로운 문서를 상위로 올리는 민감도가 낮을 수 있고, 개별 점수의 세기를 반영하지 못한다는 한계.

Adaptive Fusion의 성능 개선:

앞서 언급한대로 in-domain 시나리오에서는 하이브리드 융합의 이득이 줄었는데, 논문은 이를 극복하기 위해 가중치 최적화라는 적응형 전략을 적용.

즉, 단순히 동일 가중치로 두 모델의 점수를 합치는 대신, 개별 검색기마다 최적의 가중치를 학습시켜 조합하는 것.

개발 데이터(법률 QA 개발셋)를 활용하여 여러 가중치 비율을 시험한 결과, 가중치를 조정한 점수 융합(NSF tuned)은 동일 가중치 대비 향상된 성능을 보였습니다.

실제로 도메인 학습된 모델들의 조합 88가지 중 사전 튜닝 없이 성능이 향상된 것은 4가지(약 5%)에 불과했지만, 가중치 튜닝을 거친 경우에는 27가지 조합(약 30%)이 단일 모델보다 나은 성능을 냈습니다 .

향상된 조합 중 대부분(23/27)이 **NSF+가중치 튜닝** 방식을 사용한 것이었고,

튜닝 없이도 개선된 극소수 사례들, 주로 RRF처럼 내재적 결합 전략이 강건한 방법

이러한 결과는 **Adaptive Fusion**, 즉 질문/도메인에 맞춰 융합 가중치를 최적화하는 기법이

하이브리드 검색 성능 개선에 필수적

가중치 튜닝 자체는 개발셋이 필요하고 추가적인 계산을 요함

도메인 적합 모델들이 충실히 돌아가는 환경에서는

세심하게 조율된 융합만이 의미 있는 이득을 준다는 것

요약

논문의 핵심 기여 중 하나는 “퓨전을 언제 그리고 어떻게 활용해야 하는가”에 대한 가이드라인을 제시한 것

도메인 적응 전에는 폭넓게 융합하되,

도메인 적응 후에는 (필요하다면) 가중치를 조절하는 방향이 최적임을 입증

이러한 Adaptive Fusion 전략은 이후 연구에서 질의별 동적 가중치 조정이 나

학습 기반 융합 모델 등으로 확장되어, 보다 지능적으로

각 검색기의 기여도를 판단하는 알고리즘으로 발전시킬 수 있음

법률 QA 시스템에의 응용 가능성:

Know When to Fuse의 연구 결과는 법률 질의응답(Legal QA) 시스템 구축에 직접적으로 응용될 수 있음.

법률 QA에서는 사용자 질문에 대해 관련 법령 조문이나 판례를 찾아 정확한 근거와 함께 답변하는 것이 중요.

이때 RAG(Retrieval-Augmented Generation)와 같은 접근법을 사용하면 검색 단계에서 찾아온 근거 문서를 생성 모델(예: LLM)에 제공, 보다 신뢰도 높은 답변을 생성하게 할 수 있음

하이브리드 검색은 이러한 RAG 파이프라인의 초석(retrieval 단계)을 향상 시켜 줄 수 있음

예를 들어,

일반인이 “산업재해로 인정받으려면 어떤 요건이 필요한가요?”와 같이 질문할 때,

실제 관련 법 조문에서는 전문용어나 격식체로 표현되어 있는 경우

어휘 기반 검색은 사용자가 표현한 용어와 정확히 일치하는 단어가 없으면 해당 조문을 놓칠 수 있지만,

의미 기반 검색 모델은 질문을 의미적으로 해석하여 유사한 맥락의 조문을 찾을 수 있습니다.

반대로, 법률 질문에 특정 조항 번호나 키워드가 포함된 경우

어휘 기반 검색이 빠르게 해당 조문을 찾는데 유리합니다.

따라서 두 방식을 결합한 하이브리드 검색은

다양한 유형의 질문에 대해 더 높은 재현율(**Recall**)을 보장하여, 이후 생성 모델이 참조할 풍부한 근거를 확보하게 해줍니다 .

실제 논문에서 보여준 바와 같이, 하이브리드 검색은 단일 검색기가 간과한 문서도 포착하므로 법률 QA 시스템에서 **정답 근거 누락을 줄이는 역할**을 할 수 있습니다.

이는 곧 QA 시스템의 정확도 향상으로 이어집니다.

법률 답변은 근거가 특히 중요한데, 하이브리드 검색으로 **다양한 표현의 관련 법률 조각들을 망라함**으로써 LLM이 잘못된 사실을 생성하거나 임의로 지식을 만들어내는 **환각(hallucination)**을 줄이고 사실성을 높일 수 있습니다 .

예컨대, 한국어 법률 QA에서 GPT-4 같은 모델을 쓸 때 하이브리드 검색을 통해 관련 법 조항 원문들을 모두 제공하면, 모델은 이를 참고하여 정확한 조항 번호와 내용을 인용하면서 답을 제시할 확률이 높아집니다.

또한 하이브리드 검색은 **제로샷 법률 QA**에도 유용한데, 새로운 유형의 질문이 들어와도 사전에 학습되지 않은 조문을 BM25 등이 찾아내어 맥락을 제공

할 수 있기 때문입니다 .

이러한 이유로 Know When to Fuse의 발견은 법률 QA 시스템의 검색 모듈을 설계할 때 어떤 상황에서 어떤 검색 조합을 써야 최적의 답변 정확도를 얻을지에 대한 근거를 제공한다.

요약하면, 법률 **QA** 응용에서 하이브리드 검색의 가치는

- (1) 법률처럼 어려운 도메인에서 높은 재현율로 관련 근거를 수집하고,
- (2) LLM 기반 생성 답변의 사실적 정확성과 신뢰도를 높이며,
- (3) 데이터가 부족한 환경에서도 튜닝 없이 비교적 좋은 성능을 낼 수 있다는 점

Boost-RAG: 기존 연구와의 비교 및 기여점

Boost-RAG : *Boost-RAG*는 위 논문의 성과를 바탕으로 제안되는 비영어권 법률 **QA** 특화 검색-생성 통합 시스템이라 할 수 있습니다.

이름에서 나타나듯 “Boosted RAG”는 **Retrieval-Augmented Generation** 기법에 부스트(향상)된 검색 모듈을 접목한 것을 의미하며, 특히 한국어 등 비영어권 법률 도메인에 초점을 맞춘 연구입니다.

Boost-RAG는 궁극적으로 질문에 대한 정확한 답변을 생성하는 시스템이지만, 그 핵심 기술적 기여는 백엔드에서 동작하는 향상된 하이브리드 검색과 적응형 퓨전(**Adaptive Fusion**)에 있습니다. 이는 *Know When to Fuse* 논문이 주로 다룬 검색 단계의 최적화를, 실제 QA 파이프라인에 통합하여 엔드투엔드 성능을 향상시키는 시도라 볼 수 있습니다.

Know When to Fuse vs. Boost-RAG – 연구 범위의 차이:

앞서 요약한 Know When to Fuse는
검색 자체의 성능 향상과 통찰에 집중한 반면,

Boost-RAG는 한 걸음 더 나아가 검색 결과를 활용한 답변 생성 단계까지 고려한다는 차이가 있습니다.

다시 말해 KWtF가

“어떤 검색 조합이 법률문서를 잘 찾아주는가”에 초점을 두었다면, Boost-RAG는 “어떻게 찾아진 문서를 활용하여 더 정확하고 신뢰할 수 있는 답변을 만들 것인가”까지 포괄함.

이로써 Boost-RAG는 하이브리드 검색 연구를 실제 응용 시스템에 연결짓는 가교 역할을 함.

예컨대, KWtF에서 제시된 최적의 검색 조합과 퓨전 기법들이 Boost-RAG의 검색 모듈에 채택되고, 그 효과가 질문답변 정확도 향상으로 실증된다면 이는 Boost-RAG의 큰 기여가 될 것

Boost-RAG의 핵심 기여점

• 비영어권 법률 검색 최적화

Boost-RAG는 한국어와 같이 영어와 구조가 상이하고 전문 용어체계가 독자적인 비영어 법률 언어에서 검색 성능을 높이는 것을 주요 목표.

이는 프랑스어를 다룬 KWtF의 맥락을 한국어로 확장하는 것으로, 새로운 언어에서 하이브리드 검색의 효과를 검증하고 최적화 전략을 개발하는 것.

한국어 법률 문서의 경우 형태소 분석, 한자어/순우리말 혼용, 긴 문장 등 추가 난제가 있으므로, Boost-RAG는 BM25와 같은 전통 기법을 한국어 형태소 단위로 개선하거나, 다국어 Dense 모델을 한국 법률 데이터로 미세조정하는 등의 방법으로 언어 특화 최적화를 시도.

기존 연구 중 한국어 법률 질의응답에 대한 사례가 거의 전무하기 때문에, Boost-RAG는 한국어 법률 **QA**를 위한 최초의 하이브리드 **RAG** 시스템으로

자리매김할 수 있음.

이는 법률 AI 연구 커뮤니티에 새로운 언어에 대한 데이터를 제공하고, 향후 다국어 법률 QA 벤치마크 구축에도 기여하는 점에서 의의가 큼.

• **Adaptive Fusion** 기법의 개선

Boost-RAG는 KWtF 논문에서 강조된 가중치 기반 융합 최적화를 한 단계 발전시켜, 보다 자동화되고 지능적인 퓨전 메커니즘을 도입

KWtF에서는 개발셋을 활용한 수동적인 가중치 튜닝으로 융합 성능을 높였다면, Boost-RAG에서는 학습 기반의 퓨전 모델,질의별 동적 가중치 결정 알고리즘 제안

예를 들어, Boost-RAG는 간단한 선형 결합이 아니라

메타-랭커(meta-ranker)를 활용해

각 후보 문서의 BM25 점수, DPR 점수, 기타 특징들을 입력으로 받아

해당 문서의 최종 중요도 점수를

예측하는 앙상블 랭킹 모델을 훈련할 수 있음

혹은, 질문 분류를 통해 질의가 법률 용어나 조항 번호를 직접 포함하는지, 서술적 문의인지 등을 판단한 뒤,

질문 유형에 따라 BM25 vs Dense 모델의 비중을

가변적으로 적용하는 방안도 생각할 수 있음.

이런 **Adaptive Fusion**은 고정된 가중치 융합보다

한층 세밀하게 각 검색기의 강점을 살리고 약점을 보완하는 역할

Boost-RAG 논문에서는 이러한 방법론적 기여를 이론적으로 제시하고,

실험적으로 KWtF에서 사용한 단순 NSF 튜닝이나 RRF 대비

향상된 검색 성능을 입증해야함

가령, Boost-RAG의 학습된 퓨전 모델이

KWtF의 튜닝된 NSF보다 일관되게 높은 MRR이나 Recall을 보인다면,

이는 **Adaptive Fusion** 기법의 최신 개선 결과로서 가치가 있음

• 검색-생성 통합 및 법률 QA 성능 향상

Boost-RAG의 최종 지향점은 검색 모듈의 개선이 **QA 성능**으로 이어짐을 증명

따라서 Boost-RAG는 검색 단계에서 얻은 문서들을 활용하여 답변을 생성하는 **RAG** 파이프라인을 구현하고, end-to-end로 평가.

Boost-RAG의 기여

첫째, 사실 기반 답변 생성:

하이브리드 검색을 통해 얻은 법률 조항들을 LLM에 제공함으로써, 순수 LLM 답변보다 정확도가 높고 출처가 명시된 법률 답변을 생성.

둘째, 모델 경량화 및 학습 효율성:

Boost-RAG는 방대한 파라미터를 가진 LLM을 법률 데이터로 풀 파인튜닝하지 않고서도, 검색 모듈 최적화만으로 성능을 끌어올릴 수 있음

이는 법률같이 데이터 적고 보수적인 도메인에서 현실적으로 유용한 접근법.

예컨대, 법률 자문 AI를 만들 때 거대 모델을 새로 학습시키기보다,

상대적으로 작은 검색기(수백만~수억 파라미터 수준)를 잘 결합하여, 기본 LLM에 법률 지식을 주입하는 형태로도 충분한 성능을 달성할 수 있다는 메시지를 줄 수 있음

요약하면, Boost-RAG는

***“검색 최적화가 궁극적으로 답변 품질 향상으로 이어진다”는 것을 실제 한국어 법률 QA 과제를 통해 보여줌으로써, 기존 KWtF 연구를 응용 측면에서 확장·발전.

• 기타 차별점: Boost-RAG는 또한 법률 도메인 특화 기능을 더할 수 있음.

예를 들어, 법률 문서 간 인용 관계나 조문 구조(목차/번호 등)를 활용한 검색 개선, 또는 다국어 법률 질의에 대비한 기계번역 결합 검색 등은 KWtF에서 다루지 않은 영역.

Boost-RAG가 적용 범위를 넓히고 독창성을 갖는 방향으로 고려되는 부분. (예: 사용자가 영어로 질문해도 한국어 법률에서 답을 찾기 위해, 질문을 번역하여 한영 양쪽에서 검색한 후 결과를 융합하는 크로스링갈 검색 확장 등).

Boost-RAG의 기여

- (a) KWtF의 하이브리드 검색 통찰을 한국어 법률 QA로 확장하고,
- (b) Adaptive Fusion을 고도화하며,
- (c) 검색과 생성의 접목을 통해 실질적인 QA 성능 향상을 입증.

기존 KWtF 논문이 순수 IR 관점의 연구, Boost-RAG는 **IR+QA 융합 연구**로서

학술적 가치와 응용적 가치를 동시에 추구한다는 점에서 차별화.

Boost-RAG의 연구 방향 및 논문 가치 향상 방안

Boost-RAG에 대해 구체적으로 제안하는 연구 방향과 개선 사항

1. 비영어권 법률 검색 최적화 전략 수립

• 다국어 사전학습 모델 활용 및 미세조정:

한국어 법률 도메인에서는 대규모 학습데이터가 부족하므로, 우선 다국어로 학습된 범용 Dense Retriever 모델(e.g., mBERT, multilingual E5 등)을 활용한 제로샷 검색 성능을 평가.

KWtF가 프랑스어 MS MARCO 번역본(mMARCO-fr)을 활용했던 접근과 유사, 영어나 다국어 일반 QA 코퍼스에서 학습된 모델을 한국어에 적용해보는 단계

그런 다음 한국어 법률 QA 데이터(예: 판례 질의응답 데이터 등)가 소량이라도 있다면 해당 모델들을 미세조정(**finetuning**)하여 성능 향상을 도모.

이때 BM25와 미세조정된 Dense 모델의 상대적 성능 변화를 관찰함으로써, KWtF에서와 동일하게 **zero-shot vs. in-domain** 환경에서 어느 정도 차이가 나는지 확인할 수 있음.

이러한 실험은 KWtF의 결과를 한국어 법률이라는 새 환경에서 재검증하는 것으로, 하이브리드 검색 성능 패턴의 일관성 또는 차이점을 파악하게 해줄 것.

• 토큰화 및 전처리 최적화:

한국어는 어미변화와 조사 등으로 단어 형태가 다양하게 변화하므로, BM25 같은 전통 검색의 효과를 높이기 위해서는 형태소 단위의 인덱싱이나 법률 용어 사전에 기반한 전처리가 필요.

Boost-RAG 연구에서는

BM25 baseline의 성능을 극대화하기 위해
한국어에 최적화된 형태소 분석기를 적용하고,
법률 용어를 사용자 사전으로 추가하거나,
한자어/약어 정규화 등을 수행하는 실험을 제안.

이러한 검색 최적화 기법은 단일 BM25 성능을 끌어올려 줄 뿐 아니라, 이후 Dense 모델과의 결합 시 어휘 신호를 더 풍부하게 제공하여 융합 효과도 향상시킬 수 있음.

• 도메인 지식 통합

- 법률 도메인만의 특성(조문 구조, 판례의 인용관계)을 검색에 활용하는 방안도 고려. 예를 들어, 법률 조문의 계층적 구조(헌법 > 법률 > 시행령 > 조항 등)나 연관 조항 링크를 그래프로 구축하여, 검색 결과에 해당 조항과 인접 조항을 함께 제시하거나, 검색 점수에 인접노드 정보를 반영할 수 있음.
- Louis et al.(2023)에서는 법률 조문의 토폴로지(구조)를 임베딩에 반영한 그래프 강화 검색 모델을 제안한 바 있는데 , Boost-RAG에서도 이러한 아이디어를 차용하여, BM25/Dense 결과에 법률 구조적인 보정을 추가하면 보다 맥락에 맞는 검색이 될 수 있음.
- 비록 이러한 기법이 KWtF에서는 다루어지지 않았지만, Boost-RAG의 연구 범위를 확장하고 법률 도메인에 특화된 차별성을 부여하는 요소로 가치가 있음

• 성능 및 효율성 균형

- 비영어 대용량 법률말뭉치에서의 검색은 성능뿐 아니라 **실용적 효율성**도 고려해야 함
- KWtF에서도 BM25는 효율이 높고 Dense는 비용이 큰 차이를 보임을 언급했듯이, Boost-RAG에서는 실제 시스템 적용을念頭에 두고 **속도와 메모리 사용량** 평가도 진행해야 함.
- 예컨대 한국어 법령 약 10만 조항, 판례 수십만 건 규모 코퍼스를 가정하면, BM25는 인덱스 생성이 용이하나
- Dense는 수백만 임베딩 저장 및 실시간 유사도 계산 비용이 있음.
- 따라서 **하이브리드 캐스케이드(cascade)** 검색을 사용해 초기 후보군은 BM25로 빠르게 뽑고, Dense로 재랭킹하거나 추가 검색하는 2단계 접근을 제안. 이 방식은 KWtF처럼 동시 융합과 유사한 효과를 내면서도, 대역폭을 줄여 효율성을 높여줌.
- Boost-RAG 실험 설계 시 BM25 top-k를 Dense가 재정렬했을 때 성능저하 없이 검색 시간이 얼마나 개선되는지 측정하면, **실무적인 최적화 전략**을 제시할 수 있을 것.

2. Adaptive Fusion 기법의 고도화

• 가중치 튜닝 자동화 및 학습:

KWtF에서 확인된 바와 같이 도메인 특화 상황에서는 가중치 최적화가 성능 향상의 열쇠.

Boost-RAG에서는 이 가중치 결정을 자동화하고 일반화하기 위해 학습 기반 **Fusion**을 모색.

우선 간단한 접근으로, 개발셋을 활용해

grid search 또는 **Bayesian optimization**으로

BM25 vs Dense의 최적 가중치를 찾아 적용할 수 있음.

하지만 더 나아가, 질의마다 최적 가중치가 다를 수 있으므로, 질의 특성에 대응하는 가중치 예측 모델을 제안할 수 있음.

예를 들어, 질의를 입력으로 받아 BM25 비중을 얼마로 할지 예측하는
소규모 분류기/회귀모델을 학습시키는 것.

->이 모델은 질의에 포함된 전문용어 비율, 질의 길이, 형태소 다양도 등의 특징을 활용하여, BM25가 유리한 질의인지 Dense가 유리한 질의인지 판별할 수 있을 것. 이러한 **Adaptive weighting**은 논문 기여로서 새롭게 제시 가능하며, 실험으로 특정 질의군에서는 BM25 위주 융합이, 다른 군에서는 Dense 위주 융합이 효과적임을 보인다면 설득력을 갖게 됨.

• Meta-ranker 도입:

앞서 잠시 언급한 메타-랭커는, 개별 검색 모델들의 출력을 입력 피처로 받아 최종 랭킹을 직접 학습하는 머신러닝 모델.

예를 들면, XGBoost나 랭크 SVM과 같은 알고리즘을 사용하여, <문서, BM25점수, Dense1점수, Dense2존재여부, ...> 등의 피처를 학습하고 해당 문서의 최종 점수를 예측하도록 할 수 있음.

학습 라벨은 사람이 평가한 관련도 점수나, 또는 QA 데이터셋에서 해당 문서가 정답 근거인지 여부로 설정합니다. 이렇게 하면 단순 선형 가중합을 넘어, 비선형적이고 문맥적인 융합이 가능해짐.

예컨대 BM25와 Dense 모델이 모두 높게 점수 준 문서는 시너지가 있으므로 더 높게, 한 쪽만 높게 준 문서는 적절히 가중 처리하는 식.

Pinecone 연구팀의 Bruch 등(2023)의 연구에서도 다양한 Fusion 함수를 분석하고 학습 기반 결합이 잠재력을 보임을 시사했는데, Boost-RAG는 이러한 최신 기법을 법률 QA 맥락에 접목하여 **Fusion 함수의 성능 향상을** 실증할 수 있음.

• Dynamic Document Selection

Fusion의 또 다른 개선 방향은 문서 선택 단계에서의 적응.

일반적인 융합은 각 모델의 top-k 결과를 모두 합치는 것이지만, 때로는 특정 모델의 결과가 노이즈일 경우 이를 배제하는 편이 좋을 수 있음.

Boost-RAG에서는 동적 문서 필터링 전략도 실험할 수 있음.

예를 들어, Dense 모델이 가져온 문서들 중

BM25 점수가 극도로 낮은 문서를 걸러내거나

(즉, 의미적으로는 유사하지만 어휘 공통점이 거의 없어 엉뚱할 가능성 배제),

반대로 BM25 top 문서들 중 Dense 임베딩 유사도가 극히 낮은 문서를 걸러내는 방식.

이러한 사전 필터링은 융합 전에 상호 보완적이지 않은 결과를 제거함으로써, 최종 융합의 정확성을 높일 수 있음.

이는 일종의 “융합 시 아웃라이어 제거”로 볼 수 있으며,

적절한 임계값을 설정하면 성능 향상에 도움이 될 것.

• 생성 모델과의 상호작용 활용:

Boost-RAG의 특이점은 최종적으로 생성 모델이 있다는 점이므로, 생성 모델의 피드백을 사용한 퓨전 개선도 고려.

예를 들어, 초기 검색 결과를 LLM에게 전달한 뒤,

LLM이 “추가로 에 관한 조항도 찾아주세요”와 같이

보강 검색 요청을 생성하게 할 수 있음.

이는 일종의 **iterative retrieval**로서,

1차 검색-생성 후 2차 검색을 수행하고 답변을 개선하는 방법.

이러한 접근을 통해, 단순 일회성 융합을 넘어 대화형/적응형 검색을 구현할 수 있음

다만 이는 시스템 복잡도를 상당히 높이는 방향이므로, Boost-RAG 논문에서는 주된 초점이라기보다는 부록적인 실험이나 향후 연구 제안으로 언급하는 정도가 적절

3. 법률 QA 성능 평가 및 실험 설계

- **엔드투엔드 QA 평가:**

Boost-RAG의 가치를 증명하기 위해 가장 중요한 것은 **QA 최종 성능 평가**. 단순 IR 평가 (Recall, MRR 등)에서 더 나아가, 실제 질문에 대한 **정답 생성의 정확도**를 측정해야 함.

이를 위해 적절한 **법률 QA 테스트 세트**를 구성하거나 기존 데이터를 활용. 가능하다면 정답에 대한 **정량 평가 지표**(예: Exact Match, F1 등)가 있는 데이터셋이 좋겠지만, 법률 QA의 답변은 서술적일 수 있으므로 **전문가 평가나 평결 기반 평가**를 병행할 수도 있음.

예를 들어, Boost-RAG가 생성한 답변과 해당 질문에 대한 변호사 또는 법학 전문가의 모범 답변을 비교하여, 중요 조항이 제대로 포함되었는지, 사실 관계가 맞는지 등을 체크합니다.

또는 NLLP 2023에서 제안된 Eval-RAG 방식처럼, **Retriever를 이용해 생성 답변의 사실 여부를 검증하는 방법**도 활용할 수 있습니다 .

구체적으로, LLM이 산출한 답변을 다시 Boost-RAG의 검색기로 확인하여, 답변의 핵심 내용이 검색되는지 확인함으로써 신뢰도를 측정하는 방안. 이러한 이중 평가 방법은 자동화된 지표가 부족한 경우에도 모델의 실효성을 뒷받침해 줄 데이터 포인트를 제공.

- **IR 성과와 QA 성과의 상관관계 분석:** 하이브리드 검색의 향상이 실제 답변 향상으로 어떻게 이어지는지를 과학적으로 분석하기 위해, **단계별 평가**를 실시합니다. 예를 들어, 단일 BM25 사용, 단일 Dense 사용, BM25+Dense 융합 (Boost-RAG 방식) 세 설정에서 (a) Top-k 문서 검색 성과와 (b) 최종 답변 정확도를 각각 측정하여 비교합니다. 기대대로라면 Boost-RAG 융합 설정이 (a)에서 가장 높은 Recall@k를 보이고, (b)에서도 가장 높은 답변 정확도를 보여야 합니다. 만약 IR 향상 대비 QA 향상이 미진한 경우, 그 원인을 분석해야 합니다 (예: 검색이 향상된 문서는 부차적인 정보여서 답변에 큰 영향이 없었다든지). 이러한 **상관분석**은 Boost-RAG의 설득력을 높여주며, 향

후 연구에서 어느 수준의 IR 개선이 QA 개선으로 직결되는지 가이드라인을 제공해줄 수 있습니다.

- **Baseline 및 기존 기법과의 비교:** Boost-RAG 논문의 실험 설계에는 반드시 기존 기법과의 비교가 포함되어야 합니다. 예컨대, 기존 RAG 접근(단일 Dense retriever + generative model)과 Boost-RAG(하이브리드 retriever + generative model)를 비교하거나, KWtF에서 최적이라고 한 Fusion 방법(NSF tuned, RRF 등)과 Boost-RAG의 adaptive fusion을 비교하는 실험을 제안합니다. 이를 통해 Boost-RAG의 상대적 우수성을 입증할 수 있습니다. 또한 Bruch et al.(2023)의 **SRRF**(Scaled Reciprocal Rank Fusion) 등 최근 제안된 개선된 융합 함수와도 비교하면, 연구의 포괄성과 완성도를 높일 수 있습니다. 만약 한국어 법률 QA에 대한 선행 연구가 있다면 (예: 법률 질의에 BM25만 사용한 검색 기반 QA 시스템 등), 그에 대해서도 벤치마크 비교를 수행하여 Boost-RAG의 향상폭을 정량적으로 제시합니다.

- **오픈도메인 vs 도메인 특화 설정 실험:** KWtF의 주요 통찰 중 하나는 도메인 데이터 유무에 따른 효과 차이였으므로, Boost-RAG도 가능하다면 두 환경을 모두 평가해보길 제안합니다. 즉, 법률 QA에 대해 학습되지 않은 범용 모델들로 구성된 시스템(예: mBERT 기반 retriever + ChatGPT 등)과, 한국어 법률 QA 데이터로 일부 미세조정된 시스템(Boost-RAG full)을 각각 구축하여 성능 비교를 합니다. Zero-shot 상황에서는 하이브리드가 얼마나 도움이 되었는지, in-domain 상황에서는 Boost-RAG의 adaptive fusion이 어떤 역할을 하는지 확인할 수 있습니다. 예컨대, 한국어 법률 QA 데이터가 극히 적은 경우 Boost-RAG (BM25+다국어-DPR 조합)가 단일 다국어-DPR보다 현저히 정확한 답변을 제공한다면, 이는 데이터 부족 상황에서 하이브리드의 유용성을 강조하는 결과가 됩니다. 반면 충분한 데이터로 DPR을 한국어 법률에 특화했더니 BM25의 기여가 줄어드는 양상이 확인된다면, KWtF의 발견이 다른 언어에서도 재현됨을 보여주는 의미가 있습니다.

4. 논문의 가치 극대화를 위한 추가 고려사항

- **추가 실험 (케이스 스터디):** 정량 평가 외에도, 질문 유형별 사례 분석을 포함하면 논문의 깊이가 더해집니다. 예를 들어 Boost-RAG가 단일 모델로는 찾지 못한 법률 근거를 성공적으로 찾아 답변한 사례, 반대로 융합으로 인해 오류가 난 사례 등을 qualitatively 분석합니다. 이러한 사례를 통해 언제 하이브리드가 효과적이고 언제 한계가 있는지 논의하면, 독자가 Boost-RAG의 적용 범위를 이해하는 데 도움이 됩니다.

- **법률 전문가 평가:** 가능하다면 최종 답변에 대해 법률 전문가(변호사 등)의 평가를 받아 보는 것도 좋습니다. “관련 조항을 빠뜨리지 않고 인용했는가”, “법적 해석이 타당한가” 같은 기준으로 Boost-RAG와 비교 대상 시스템의 답변을 블라인드 테스트하면, 현실적인 유용성 측면에서 어떤 개선을 이루었는지 어필할 수 있습니다. 이는 학술적인 엄밀함뿐 아니라 실제 실무 적용 가능성을 보여주는 지표가 될 것입니다.

- **선행 연구와의 연계 및 인용:** Boost-RAG 논문에서는 반드시 관련 선행 연구들을 폭넓게 다루고, 자신의 위치를 명확히 해야 합니다. 예를 들어, KWtF 논문 뿐만 아니라 하이브리드 검색 일반 연구(예: Seo 등 2022, Chen 등 2022의 OOD 융합 연구 등)를 언급하고, 무엇이 달라졌는지 쓰는 것입니다. 또 법률 AI 분야의 배경으로, 기존에 법률 조항 검색이나 판례 질의응답에 쓰인 IR/QA 기법들을 조사하여 참조합니다. 그리고 **RAG** 기법 자체의 장점 (factuality 제고 등)을 법률 도메인에 적용한 시도들도 찾아 인용하면 좋습니다. 예컨대 *LegalBench-RAG* (2024)라는 최신 벤치마크 논문이 있는데, 법률 도메인에 특화된 RAG 평가를 다루므로 참고 가능하고, Thomson Reuters 등에서 설명한 법률 분야 RAG 개념글도 인용해 응용의 필요성을 강조할 수 있습니다. 이러한 풍부한 관련 연구 언급은 Boost-RAG의 기여를 더 부각시켜주며, 독자로 하여금 해당 분야의 맥락에서 이 연구가 왜 중요한지 이해하게 만듭니다.

- **재현 가능성과 공개:** 연구의 완성도를 높이기 위해 Boost-RAG의 코드, 데이터셋 (가능한 범위 내에서 변형/가공하여) 등을 공개하는 계획도 기술하면 좋습니다. KWtF도 깃허브에 코드를 공개하여 연구 재현성을 높였듯이, Boost-RAG도 법률 QA용 하이브리드 검색 베이스라인을 제공하면 이후 연

구자들이 활용할 수 있어 영향력이 커집니다. 특히 한국어 법률 QA 데이터셋이나 멀티모달 검색 결과 등의 자원을 함께 제공하면 학술적 가치가 배가될 것입니다.

마지막으로, Boost-RAG가 논문으로서 가지는 가치는 “검색 알고리즘의 개선이 실제 응용 문제 해결에 어떻게 기여하는가”를 보여주는 데 있습니다. 철저한 실험과 분석을 통해, 하이브리드 검색 및 Adaptive Fusion의 이론적 이점이 한국어 법률 질의응답처럼 난이도 높은 실제 문제에서 **정량적 성능 향상**과 **정성적 품질 개선**으로 나타남을 입증한다면, Boost-RAG는 학계와 산업계 모두에 의미 있는 연구로 인정받을 것입니다. KWtF가 열어둔 하이브리드 검색의 가능성을 이어받아, Boost-RAG는 그 가능성을 **현실의 QA 시스템**으로 꽃피우는 방향으로 연구를 추진해야 할 것입니다. 이러한 방향성에 맞추어 제시된 실험과 개선들을 성실히 구현한다면, Boost-RAG 논문은 **비영어권 법률 AI 분야의 중요한 이정표**가 될 것으로 기대됩니다.

참고문헌: (본문 내에 각주 형식으로 인용된 논문들과 법률 AI 관련 자료들)

<https://arxiv.org/html/2408.10343#:~:text=LegalBench,systems%20in%20the%20legal%20domain>

